

Data analysis & Exploration

Amine FERDJAOUI
amine.ferdjaoui@sogeti.com

Master II Machine Learning pour la Science des données
Année universitaire 2026/2027


Data Representation

A machine does not “see” an image, does not “understand” text, and does not “hear” sound the way we do.

It essentially works with numbers.

The challenge of data representation therefore lies in transforming each type of data into a usable numerical representation.

Data representation



Tabular Data

Rows and columns

Tabular data

- Rows = observations (samples)
- Columns = features (variables)
- Most common format in data science (CSV, SQL tables, pandas DataFrames, Matlab)
- Example: a dataset of students with columns *Age*, *Grade*, *Gender*

	Age	Note	Absences
Alice	22	15	2
Bob	24	11	7

Data representation




Image Data

Pixel grids

Image data

- Represented as arrays (matrices) of pixel values (grayscale or RGB)
- Can be high-dimensional and require feature extraction (CNNs, filters)
- Examples: photographs, medical scans, satellite images



Video data


Sequence of
images

Video data

- Sequence of images (frames) + often audio track
- Very high dimensional, combines spatial + temporal information
- Examples: surveillance cameras, action recognition

Data representation

Greyscale



△


```

0 2 15 0 0 11 10 0 0 0 0 9 9 0 0 0
0 0 0 4 60 157 236 255 255 177 95 61 32 0 0 29
0 10 16 119 238 255 244 245 243 250 249 255 222 103 10 0
0 14 170 255 255 244 254 255 253 245 255 249 253 251 124 1
2 98 255 228 255 251 254 211 141 116 122 215 251 238 255 49
13 217 243 255 155 33 226 52 2 0 10 13 232 255 255 36
16 229 252 254 49 12 0 0 7 7 0 70 237 252 235 62
6 141 245 255 212 25 11 9 3 0 115 236 243 255 137 0
0 87 252 250 248 215 60 0 1 121 252 255 248 144 6 0
0 13 113 255 255 245 255 182 181 248 252 242 208 36 0 19
1 0 5 117 251 255 241 255 247 255 241 162 17 0 7 0
0 0 0 4 58 251 255 246 254 253 255 120 11 0 1 0
0 0 4 97 255 255 255 248 252 255 244 255 182 10 0 4
0 22 206 252 246 251 241 100 24 113 255 245 255 194 9 0
0 111 255 242 255 158 24 0 0 6 39 255 232 230 56 0
0 218 251 250 137 7 11 0 0 0 2 62 255 250 125 3
0 173 255 255 101 9 20 0 13 3 13 182 251 245 61 0
0 107 251 241 255 230 98 55 19 118 217 248 253 255 52 4
0 18 146 250 255 247 255 255 255 249 255 240 255 129 0 5
0 0 23 113 215 255 250 248 255 255 248 248 118 14 12 0
0 0 6 1 0 52 153 233 255 252 147 37 0 0 4 1
0 0 5 5 0 0 0 0 0 14 1 0 6 6 0 0

```

Data representation

RGB



Data representation




Audio Data

Sound waves

Audio data

- Raw waveform signals or transformed (spectrograms, MFCCs)
- Used in speech recognition
- Example: voice commands, sound classification



Time Series Data

Sequences over time

Time series data

- Data indexed by time (ordered sequence)
- Each point depends on temporal order
- Examples: stock prices, weather data, sensor readings



Graph Data

Nodes and edges

Graph / Network data

- Nodes (entities) + edges (relationships)
- Captures connections between objects
- Examples: social networks, citation networks, molecules

Text data: Bag of Words



Text Data

Sequences of tokens

1 Raw documents

D1: *The algorithm demonstrates significant improvements in accuracy.*

D2: *The proposed model achieves higher performance on benchmark datasets.*

D3: *Experimental results confirm the effectiveness of the algorithm.*

2 Preprocessing

D1: algorithm demonstrate significant improvement accuracy

D2: proposed model achieve high performance benchmark dataset

D3: experimental result confirm effectiveness algorithm

Vocabulary:

{algorithm, demonstrate, significant, improvement, accuracy, proposed, model, achieve, high, performance, benchmark, dataset, experimental, result, confirm, effectiveness}

3 Bag-of-Words Matrix

	algorithm	demonstrate	improvement	accuracy	model	performance	dataset	result	effectiveness	BoW Vector representation
D1	1	1	1	1	0	0	0	0	0	[1,1,1,1,0,0,0,0,0]
D2	0	0	0	0	1	1	1	0	0	[0,0,0,0,1,1,1,0,0]
D3	1	0	0	0	0	0	0	1	1	[1,1,1,1,0,0,0,0,0]

Text data: TF-IDF

Raw documents

D1: *The neural network improved accuracy on benchmark datasets.*
D2: *Deep learning improves high performance with large datasets.*
D3: *The clinical trial demonstrates significant treatment effects.*
D4: *Medical researchers report improved patient outcomes in the trial.*

Raw documents preprocessed

D1: neural network improve accuracy benchmark dataset
D2: deep learning improve high performance large dataset
D3: clinical trial demonstrate significant treatment effect
D4: medical researcher report improve patient outcome trial


Bag-of-Words Matrix

	dataset	accuracy	performance	trial	treatment	patient	improve	...
D1	1	1	0	0	0	0	1	...
D2	1	0	1	0	0	0	1	...
D3	0	0	0	1	1	0	0	...
D4	0	0	0	1	0	1	1	...

TF-IDF Matrix

	dataset	accuracy	performance	trial	treatment	patient	improve	...
D1	0.69	1.39	0.00	0.00	0.00	0.00	0.29	...
D2	0.69	0.00	1.39	0.00	0.00	0.00	0.29	...
D3	0.00	0.00	0.00	0.69	1.39	0.00	0.00	...
D4	0.00	0.00	0.00	0.69	0.00	1.39	0.29	...


Text data: Word Embedding



Word	Dimension 1	Dimension 2	Dimension 3	Word Embedding Vector
goose	2	0	4	[2, 0, 4]
eagle	3	0	3	[3, 0, 3]
bee	3	0	2	[3, 0, 2]
helicopter	0	2	4	[0, 2, 4]
drone	0	3	3	[0, 3, 4]
rocket	0	4	2	[0, 4, 2]
jet	1	1	1	[1, 1, 1]

Examples: word2vec, fasttext, BERT, etc.

Text data: Sentence Embedding



Documents	Dimension 1	Dimension 2	Dimension 3	Sentence Embedding Vector
doc1	0.23	-0.41	0.12	[0.23, -0.41, 0.12]
doc2	0.19	-0.38	0.15	[0.19, -0.38, 0.15]
doc3	0.20	-0.35	0.08	[0.20, -0.35, 0.08]
doc4	-0.12	0.33	-0.07	[-0.12, 0.33, -0.07]
doc5	-0.15	0.36	-0.05	[-0.15, 0.36, -0.05]
doc6	0.40	0.12	-0.19	[0.40, 0.12, -0.19]
doc7	0.44	0.09	-0.23	[0.44, 0.09, -0.23]

Examples: Mpnet, MiniLM, BGE, E5, Qwen, etc.

Envoyer les Tp à :
mlds.git@gmail.com

1. Importer le dataset **AirPassengers**.
2. Afficher les 5 premières lignes.
3. Convertir la colonne *date* en index temporel (`pd.to_datetime`).
4. Visualiser la série.
5. Calculer et tracer une **moyenne mobile** (fenêtre 12 mois).
6. Décomposer la série (tendance + saisonnalité + résidus) avec `statsmodels`.

1. Charger un fichier audio .wav ou .ogg avec librosa.
2. Afficher la taille du signal et sa durée.
3. Tracer le **waveform**.
4. Calculer et afficher le **spectrogramme**.
5. Jouer le son dans Jupyter (IPython.display.Audio).
6. Ajoutez un bruit aléatoire au signal audio, puis comparez le signal bruité au signal original.

1. Charger un petit dataset d'images.
2. Afficher la dimension d'une image.
3. Visualiser quelques images avec matplotlib.
4. Normaliser les pixels (0-1).
5. Calculer la moyenne et l'écart-type des pixels d'une image.
6. Supprimer successivement les canaux rouge, vert et bleu. Quel est le rôle de chaque canal dans la représentation de l'image ?
7. Tracer un rectangle sur une image autour d'un objet avec OpenCV.
8. Choisissez un objet visible dans l'image et dessinez manuellement une bounding box autour de celui-ci.

1. Charger un petit clip vidéo.
2. Lire les métadonnées (fps, nombre de frames, durée).
3. Afficher la vidéo directement dans le notebook.
4. Extraire **3 frames/seconde** et les afficher.
5. Sauvegarder les frames dans un dossier.
6. Modifiez le nombre de frames par seconde utilisé lors de la lecture ou de la reconstruction de la vidéo. Comparez la vidéo originale et la vidéo modifiée.
7. Comparez deux frames successives de la vidéo (la différence entre deux frames).
Quelles parties de l'image changent ?

1. Charger un graphe .net (Pajek) avec NetworkX.
2. Afficher le nombre de nœuds et d'arêtes.
3. Visualiser le graphe avec matplotlib.
4. Calculer le degré de chaque nœud.
5. Tracer la **distribution des degrés** (histogramme).
6. Visualiser avec ipycytoscape.

1. Créer une petite collection de 5-6 documents texte.
2. Faire un **préprocessing** (lowercase, nettoyage, stopwords).
3. Construire la matrice **Bag of Words**.
4. Construire la matrice **TF-IDF**.
5. Afficher le vocabulaire extrait.
6. Utiliser Word2Vec pour les mots et afficher dans un plot 3d.
7. Utiliser MiniLM (sentence-transformers) pour les phrases et afficher dans un plot 3d.