

Data analysis & Exploration

Amine FERDJAOUI
amine.ferdjaoui@sogeti.com

Master II Machine Learning pour la Science des données
Année universitaire 2026/2027


Data Representation

A machine does not “see” an image, does not “understand” text, and does not “hear” sound the way we do.

It essentially works with numbers.

The challenge of data representation therefore lies in transforming each type of data into a usable numerical representation.

Data representation



Tabular Data

Rows and columns

Tabular data

- Rows = observations (samples)
- Columns = features (variables)
- Most common format in data science (CSV, SQL tables, pandas DataFrames, Matlab)
- Example: a dataset of students with columns *Age*, *Grade*, *Gender*

	Age	Note	Absences
Alice	22	15	2
Bob	24	11	7

Data representation



Image Data

Pixel grids

Image data

- Represented as arrays (matrices) of pixel values (grayscale or RGB)
- Can be high-dimensional and require feature extraction (CNNs, filters)
- Examples: photographs, medical scans, satellite images



Video data

Sequence of
images

Video data

- Sequence of images (frames) + often audio track
- Very high dimensional, combines spatial + temporal information
- Examples: surveillance cameras, action recognition

Data representation

Greyscale




0	2	15	0	0	11	10	0	0	0	0	9	9	0	0	0
0	0	0	4	60	157	236	255	255	177	95	61	32	0	0	29
0	10	16	119	238	255	244	245	243	250	249	255	222	103	10	0
0	14	170	255	255	244	254	255	253	245	255	249	253	251	124	1
2	98	255	228	255	251	254	211	141	116	122	215	251	238	255	49
13	217	243	255	155	33	226	52	2	0	10	13	232	255	255	36
16	229	252	254	49	12	0	0	7	7	0	70	237	252	235	62
6	141	245	255	212	25	11	9	3	0	115	236	243	255	137	0
0	87	252	250	248	215	60	0	1	121	252	255	248	144	6	0
0	13	113	255	255	245	255	182	181	248	252	242	208	36	0	19
1	0	5	117	251	255	241	255	247	255	241	162	17	0	7	0
0	0	0	4	58	251	255	246	254	253	255	120	11	0	1	0
0	0	4	97	255	255	255	248	252	255	244	255	182	10	0	4
0	22	206	252	246	251	241	100	24	113	255	245	255	194	9	0
0	111	255	242	255	158	24	0	0	6	39	255	232	230	56	0
0	218	251	250	137	7	11	0	0	0	2	62	255	250	125	3
0	173	255	255	101	9	20	0	13	3	13	182	251	245	61	0
0	107	251	241	255	230	98	55	19	118	217	248	253	255	52	4
0	18	146	250	255	247	255	255	255	249	255	240	255	129	0	5
0	0	23	113	215	255	250	248	255	255	248	248	118	14	12	0
0	0	6	1	0	52	153	233	255	252	147	37	0	0	4	1
0	0	5	5	0	0	0	0	0	14	1	0	6	6	0	0



0	2	15	0	0	11	10	0	0	0	0	9	9	0	0	0
0	0	0	4	60	157	236	255	255	177	95	61	32	0	0	29
0	10	16	119	238	255	244	245	243	250	249	255	222	103	10	0
0	14	170	255	255	244	254	255	253	245	255	249	253	251	124	1
2	98	255	228	255	251	254	211	141	116	122	215	251	238	255	49
13	217	243	255	155	33	226	52	2	0	10	13	232	255	255	36
16	229	252	254	49	12	0	0	7	7	0	70	237	252	235	62
6	141	245	255	212	25	11	9	3	0	115	236	243	255	137	0
0	87	252	250	248	215	60	0	1	121	252	255	248	144	6	0
0	13	113	255	255	245	255	182	181	248	252	242	208	36	0	19
1	0	5	117	251	255	241	255	247	255	241	162	17	0	7	0
0	0	0	4	58	251	255	246	254	253	255	120	11	0	1	0
0	0	4	97	255	255	255	248	252	255	244	255	182	10	0	4
0	22	206	252	246	251	241	100	24	113	255	245	255	194	9	0
0	111	255	242	255	158	24	0	0	6	39	255	232	230	56	0
0	218	251	250	137	7	11	0	0	0	2	62	255	250	125	3
0	173	255	255	101	9	20	0	13	3	13	182	251	245	61	0
0	107	251	241	255	230	98	55	19	118	217	248	253	255	52	4
0	18	146	250	255	247	255	255	255	249	255	240	255	129	0	5
0	0	23	113	215	255	250	248	255	255	248	248	118	14	12	0
0	0	6	1	0	52	153	233	255	252	147	37	0	0	4	1
0	0	5	5	0	0	0	0	0	14	1	0	6	6	0	0

Data representation

RGB



Data representation




Audio Data

Sound waves

Audio data

- Raw waveform signals or transformed (spectrograms, MFCCs)
- Used in speech recognition
- Example: voice commands, sound classification



Time Series Data

Sequences over time

Time series data

- Data indexed by time (ordered sequence)
- Each point depends on temporal order
- Examples: stock prices, weather data, sensor readings



Graph Data

Nodes and edges

Graph / Network data

- Nodes (entities) + edges (relationships)
- Captures connections between objects
- Examples: social networks, citation networks, molecules

Text data: Bag of Words



Text Data
Sequences of
tokens

1 Raw documents

D1: *The algorithm demonstrates significant improvements in accuracy.*
D2: *The proposed model achieves higher performance on benchmark datasets.*
D3: *Experimental results confirm the effectiveness of the algorithm.*

2 Preprocessing

D1: algorithm demonstrate significant improvement accuracy
D2: proposed model achieve high performance benchmark dataset
D3: experimental result confirm effectiveness algorithm

Vocabulary:
{algorithm, demonstrate, significant, improvement, accuracy, proposed, model, achieve, high, performance, benchmark, dataset, experimental, result, confirm, effectiveness}

3 Bag-of-Words Matrix

	algorithm	demonstrate	improvement	accuracy	model	performance	dataset	result	effectiveness	BoW Vector representation
D1	1	1	1	1	0	0	0	0	0	[1,1,1,1,0,0,0,0,0]
D2	0	0	0	0	1	1	1	0	0	[0,0,0,0,1,1,1,0,0]
D3	1	0	0	0	0	0	0	1	1	[1,1,1,1,0,0,0,0,0]

Text data: TF-IDF

Raw documents

D1: *The neural network improved accuracy on benchmark datasets.*
D2: *Deep learning improves high performance with large datasets.*
D3: *The clinical trial demonstrates significant treatment effects.*
D4: *Medical researchers report improved patient outcomes in the trial.*

Raw documents preprocessed

D1: neural network improve accuracy benchmark dataset
D2: deep learning improve high performance large dataset
D3: clinical trial demonstrate significant treatment effect
D4: medical researcher report improve patient outcome trial


Bag-of-Words Matrix

	dataset	accuracy	performance	trial	treatment	patient	improve	...
D1	1	1	0	0	0	0	1	...
D2	1	0	1	0	0	0	1	...
D3	0	0	0	1	1	0	0	...
D4	0	0	0	1	0	1	1	...

TF-IDF Matrix


	dataset	accuracy	performance	trial	treatment	patient	improve	...
D1	0.69	1.39	0.00	0.00	0.00	0.00	0.29	...
D2	0.69	0.00	1.39	0.00	0.00	0.00	0.29	...
D3	0.00	0.00	0.00	0.69	1.39	0.00	0.00	...
D4	0.00	0.00	0.00	0.69	0.00	1.39	0.29	...

Text data: Word Embedding



Word	Dimension 1	Dimension 2	Dimension 3	Word Embedding Vector
goose	2	0	4	[2, 0, 4]
eagle	3	0	3	[3, 0, 3]
bee	3	0	2	[3, 0, 2]
helicopter	0	2	4	[0, 2, 4]
drone	0	3	3	[0, 3, 4]
rocket	0	4	2	[0, 4, 2]
jet	1	1	1	[1, 1, 1]

Text data: Sentence Embedding



Documents	Dimension 1	Dimension 2	Dimension 3	Sentence Embedding Vector
doc1	0.23	-0.41	0.12	[0.23, -0.41, 0.12]
doc2	0.19	-0.38	0.15	[0.19, -0.38, 0.15]
doc3	0.20	-0.35	0.08	[0.20, -0.35, 0.08]
doc4	-0.12	0.33	-0.07	[-0.12, 0.33, -0.07]
doc5	-0.15	0.36	-0.05	[-0.15, 0.36, -0.05]
doc6	0.40	0.12	-0.19	[0.40, 0.12, -0.19]
doc7	0.44	0.09	-0.23	[0.44, 0.09, -0.23]

Envoyer les Tp à :
mlds.git@gmail.com

1. Importer le dataset **AirPassengers**.
2. Afficher les 5 premières lignes.
3. Convertir la colonne *date* en index temporel (`pd.to_datetime`).
4. Visualiser la série.
5. Calculer et tracer une **moyenne mobile** (fenêtre 12 mois).
6. Décomposer la série (tendance + saisonnalité + résidus) avec `statsmodels`.

1. Charger un fichier audio .wav ou .ogg avec librosa.
2. Afficher la taille du signal et sa durée.
3. Tracer le **waveform**.
4. Calculer et afficher le **spectrogramme**.
5. Jouer le son dans Jupyter (IPython.display.Audio).
6. Ajoutez un bruit aléatoire au signal audio, puis comparez le signal bruité au signal original.

1. Charger un petit dataset d'images.
2. Afficher la dimension d'une image.
3. Visualiser quelques images avec matplotlib.
4. Normaliser les pixels (0-1).
5. Calculer la moyenne et l'écart-type des pixels d'une image.
6. Supprimer successivement les canaux rouge, vert et bleu. Quel est le rôle de chaque canal dans la représentation de l'image ?
7. Tracer un rectangle sur une image autour d'un objet avec OpenCV.
8. Choisissez un objet visible dans l'image et dessinez manuellement une bounding box autour de celui-ci.

1. Charger un petit clip vidéo.
2. Lire les métadonnées (fps, nombre de frames, durée).
3. Afficher la vidéo directement dans le notebook.
4. Extraire **3 frames/seconde** et les afficher.
5. Sauvegarder les frames dans un dossier.
6. Modifiez le nombre de frames par seconde utilisé lors de la lecture ou de la reconstruction de la vidéo. Comparez la vidéo originale et la vidéo modifiée.
7. Comparez deux frames successives de la vidéo (la différence entre deux frames).
Quelles parties de l'image changent ?

1. Charger un graphe .net (Pajek) avec NetworkX.
2. Afficher le nombre de nœuds et d'arêtes.
3. Visualiser le graphe avec matplotlib.
4. Calculer le degré de chaque nœud.
5. Tracer la **distribution des degrés** (histogramme).
6. Visualiser avec ipycytoscape.